

YODY · KHỎI DEVOPS

Tài liệu hiện trạng hệ thống

ỨNG DỤNG ĐẶT HÀNG YODY ORDER SERVICE

Kiến trúc, cấu hình, hiệu năng, và hiện trạng vận hành

Môi trường:	Production
Account AWS:	610881553522 (Unicorn DEV)
Region:	ap-southeast-1
Phạm vi:	API service, cơ sở dữ liệu, và hàng đợi
Phiên bản tài liệu:	1.0
Ngày soạn:	16 tháng 8 năm 2026
Người soạn:	Huỳnh Lê Nhất Nghĩa
Tình trạng:	Nội bộ

Số liệu trong tài liệu được đọc trực tiếp từ hệ thống ngày 16/08/2026

MỤC LỤC

1. Giới thiệu	4
1.1 Phạm vi và mục đích	4
1.2 Nguồn số liệu	4
1.3 Quy ước trình bày	4
2. Tổng quan kiến trúc	5
2.1 Sơ đồ luồng xử lý	5
2.2 Phân vai các thành phần	5
3. Hạ tầng triển khai	6
3.1 Máy chủ ứng dụng	6
3.2 Phiên bản và phụ thuộc	6
3.3 Quy mô dữ liệu	6
4. Hiệu năng	7
4.1 Thông lượng và độ trễ	7
4.2 Điểm nghẽn đã ghi nhận	7
5. Rủi ro và khuyến nghị	8
Phụ lục A. Lệnh vận hành	9

DANH MỤC BẢNG

Bảng 3.1. Hạ tầng máy chủ ứng dụng	6
Bảng 3.2. Phiên bản thành phần	6
Bảng 3.3. Quy mô dữ liệu	6
Bảng 4.1. Độ trễ theo endpoint	7

1. GIỚI THIỆU

1.1 Phạm vi và mục đích

Tài liệu mô tả hiện trạng của Order Service, gồm kiến trúc triển khai, cấu hình đang chạy, số liệu hiệu năng, và các rủi ro đã ghi nhận. Tài liệu không đề xuất thiết kế mới, chỉ ghi lại những gì hệ thống đang thực sự chạy tại thời điểm soạn.

1.2 Nguồn số liệu

Số liệu hạ tầng đọc từ AWS Console và AWS CLI. Số liệu ứng dụng đọc từ CloudWatch Metrics trong khoảng 7 ngày gần nhất. Số liệu cơ sở dữ liệu truy vấn trực tiếp trên replica.

1.3 Quy ước trình bày

Định danh tài nguyên, đường dẫn, và tên tham số cấu hình đặt trong phong đơn cách, ví dụ `order-svc-prod`. Con số có phân thập phân dùng dấu phẩy theo quy ước tiếng Việt. Suy luận chưa kiểm chứng luôn được ghi rõ là suy luận.

2. TỔNG QUAN KIẾN TRÚC

2.1 Sơ đồ luồng xử lý



Hình 2.1. Luồng xử lý từ người dùng tới tầng lưu trữ

2.2 Phân vai các thành phần

ECS service chịu trách nhiệm nhận request đồng bộ và ghi đơn hàng. Các việc chậm như gửi thông báo và đối soát tồn kho được đẩy sang SQS để worker xử lý riêng, nên độ trễ của API không phụ thuộc vào các hệ thống bên ngoài.

Worker chạy trên cùng cụm ECS nhưng khác service, dùng chung image và khác biến môi trường `APP_ROLE`. Điều này giúp một lần build dùng cho cả hai vai.

3. HẠ TẦNG TRIỂN KHAI

3.1 Máy chủ ứng dụng

Bảng 3.1. Hạ tầng máy chủ ứng dụng

Mục	Giá trị
Cluster	unicorn-prod-cluster
Service	order-svc-prod, launch type Fargate
Kích thước task	1 vCPU, 2 GiB
Số task mong muốn	6, tự động giãn trong khoảng 4 đến 12
Subnet	3 private subnet, không có IP công khai
Security group	sg-0a91c2f7d3e4b5c60, chỉ mở 8080 từ ALB

3.2 Phiên bản và phụ thuộc

Bảng 3.2. Phiên bản thành phần

Thành phần	Phiên bản
Runtime	Node.js 22.14.0
Framework	NestJS 11.0.6
Cơ sở dữ liệu	PostgreSQL 16.4 trên RDS
Cache	ElastiCache Redis 7.1
Image cơ sở	node:22-alpine

3.3 Quy mô dữ liệu

Bảng 3.3. Quy mô dữ liệu

Mục	Số liệu
Đơn hàng tích lũy	2.184.902
Đơn hàng mỗi ngày, trung bình 7 ngày	14.377
Người dùng, trong đó hoạt động 30 ngày	486.215 / 92.640
Kích thước cơ sở dữ liệu	213 GB
Bảng lớn nhất order_items	78 GB

Lưu ý. Bảng order_items chưa được phân vùng dữ liệu đã vượt 78 GB. Truy vấn theo khoảng thời gian dài hiện phải quét trên toàn bảng. Đây là suy luận từ kế hoạch thực thi, cần đo lại trên dữ liệu production trước khi kết luận.

4. HIỆU NĂNG

4.1 Thông lượng và độ trễ

Số liệu lấy từ CloudWatch trong 7 ngày, tính trên toàn bộ target group.

Bảng 4.1. Độ trễ theo endpoint

Endpoint	RPS	p50	p95	p99
POST /orders	18,4	96 ms	412 ms	1.240 ms
GET /orders/:id	64,2	21 ms	88 ms	190 ms
GET /orders	11,7	148 ms	910 ms	2.870 ms
POST /orders/:id/cancel	2,1	74 ms	240 ms	520 ms

4.2 Điểm nghẽn đã ghi nhận

Endpoint GET /orders có p99 gần 2,9 giây, cao hơn hẳn phần còn lại. Nguyên nhân là truy vấn phân trang dùng OFFSET trên tập kết quả lớn, nên trang càng sâu càng chậm.

```
SELECT o.*, count(*) OVER () AS total
  FROM orders o
 WHERE o.customer_id = $1
 ORDER BY o.created_at DESC
 LIMIT 20 OFFSET 4000;
```

Lưu ý. Cửa sổ count(*) OVER () buộc cơ sở dữ liệu đếm toàn bộ tập kết quả cho mỗi trang. Bỏ tổng số bản ghi, hoặc chuyển sang phân trang theo con trỏ, sẽ loại bỏ phần lớn chi phí này.

5. RỦI RO VÀ KHUYẾN NGHỊ

Bảng 5.1. Rủi ro theo mức độ

Mức	Rủi ro	Khuyến nghị
Cao	Bảng <code>order_items</code> chưa phân vùng, đã 78 GB	Phân vùng theo tháng trên <code>created_at</code> , chuyển dần dữ liệu cũ
Cao	Phân trang <code>OFFSET</code> làm p99 vượt 2,8 giây	Chuyển sang phân trang theo con trỏ, bỏ đếm tổng mỗi trang
Trung bình	Chưa có giới hạn tần suất ở tầng ALB	Bật AWS WAF rate-based rule cho các endpoint ghi
Thấp	Image cơ sở ghim theo nhãn <code>22-alpine</code> , không theo digest	Ghim theo digest để bản build lặp lại được

PHỤ LỤC A. LỆNH VẬN HÀNH

A.1 Kiểm tra trạng thái service

```
aws ecs describe-services \
  --cluster unicorn-prod-cluster \
  --services order-svc-prod \
  --query 'services[0].{running:runningCount,desired:desiredCount}'
```

A.2 Xem log lỗi gần nhất

```
aws logs tail /ecs/order-svc-prod --since 30m --follow \
  | grep -E "ERROR|FATAL|timeout"
```

A.3 Truy vấn kích thước bảng

```
SELECT relname,
       pg_size_pretty(pg_total_relation_size(relid)) AS size
FROM   pg_catalog.pg_statio_user_tables
ORDER BY pg_total_relation_size(relid) DESC
LIMIT 10;
```